




A.D. 1308
unipg
UNIVERSITÀ DEGLI STUDI
DI PERUGIA

Tesina Finale di
Signal Processing and Optimization for Big Data
Corso di Laurea Magistrale in Ingegneria Informatica e Robotica - Data Science – A.A.
2025-2026
DIPARTIMENTO DI INGEGNERIA

docente
Prof. PAOLO BANELLI

ADMM for Graph Learning and Feature Reduction on US car accident data



Studente

375437 **Emanuele Fossi** emanuele.fossi@studenti.unipg.it

0. Indice

1	Obiettivi del progetto	2
1.1	Dataset, EDA e Signal Extraction	3
2	Graph Learning	4
2.1	Analisi Spettrale nel Dominio GFT e Fondamenti Teorici del Fil- traggio	4
2.2	Costruzione Matrice di Adiacenza basata su distanza	5
2.3	Apprendimento del Grafo Ottimo tramite Algoritmo ADMM Scalato	6
3	Risultati e test	11
4	Conclusioni	15

1. Obiettivi del progetto

L'obiettivo principale di questo lavoro risiede nell'applicazione pratica delle metodologie di Graph Signal Processing (GSP) e, nello specifico, della Graph Fourier Transform (GFT), per l'analisi avanzata e la compressione di segnali urbani complessi. Il nucleo della ricerca si propone di implementare un paradigma di Graph Learning finalizzato ad apprendere la topologia ottima di un grafo stradale, utilizzando come caso di studio lo storico mensile degli incidenti automobilistici nella città di Los Angeles, partendo esclusivamente dalle osservazioni del segnale stesso.

Invece di vincolare la struttura del grafo alla distanza fisica tra i vari quartieri della città, l'algoritmo impara le connessioni strutturali e comportamentali latenti tra i quartieri analizzati, basandosi sulla reale correlazione storica dei dati. Attraverso questo approccio, la matrice di adiacenza viene ottimizzata con lo scopo esplicito di massimizzare la smoothness spettrale del segnale sul grafo appreso. Tale processo permette di concentrare la quasi totalità dell'energia informativa all'interno delle componenti a bassa frequenza, individuate dai primi autovettori della matrice Laplaciana. L'efficacia di questa rappresentazione viene successivamente validata attraverso un severo test di compressione basato su un filtro passa-basso ideale; la sfida del progetto consiste infatti nel dimostrare che, sfruttando la struttura spettrale del grafo ottimizzato, è possibile ricostruire e rappresentare fedelmente la complessa mappa spaziale degli incidenti urbani riducendo drasticamente la dimensionalità del problema.

Per superare i severi limiti computazionali dei solutori generici di fronte a problemi a elevata dimensionalità, il problema di ottimizzazione convessa per il calcolo della matrice di adiacenza ottima è stato formulato e risolto mediante lo sviluppo analitico dell'algoritmo Alternating Direction Method of Multipliers (ADMM) in forma scalata.

1.1 Dataset, EDA e Signal Extraction

Per validare l'efficacia dell'algoritmo di *Graph Learning*, l'analisi è stata condotta a partire dal dataset pubblico *US Accidents*, una grande raccolta contenente milioni di record individuali relativi ai sinistri automobilistici registrati sul suolo statunitense. Ciascun record grezzo memorizza informazioni eterogenee, spazialmente vincolate tramite coordinate GPS puntuali nei campi **Start_Lat** e **Start_Lng**, e temporalmente definite attraverso la variabile **Start_Time**. Per estrarre i dati necessari per il progetto è stata effettuata una fase di Explorative Data Analysis (EDA).

Il primo livello di elaborazione applica un filtraggio geografico per estrarre selettivamente i soli record associati alla città di Los Angeles.

Successivamente, per poter definire la struttura del grafo, le coordinate spaziali puntuali sono state discretizzate arrotondando la latitudine e la longitudine alla seconda cifra decimale, convertendo così le coordinate geografiche continue in una griglia regolare di celle urbane spesse circa 1.1 km per lato. Ciascuna cella individua un nodo univoco del grafo, identificato nel codice dalla stringa alfanumerica **Nodo_ID** e localizzato geometricamente dalle variabili **Lat_Nodo** e **Lng_Nodo**, rappresentano in maniera approssimativa abbastanza bene i vari quartieri di Los Angeles.

Una volta definita la topologia spaziale dei nodi, si è proceduto all'estrazione del vero e proprio elemento cardine del progetto: il **Graph Signal** (segnale sul grafo). Questo è rappresentato dal numero di incidenti per mese a partire dal 2016 fino ad arrivare al 2023.

Il risultato finale di questo processo EDA è una matrice ad alta densità di dimensione $N \times M$, dove $N = 348$ rappresenta il numero complessivo dei nodi attivi, ossia i quartieri, e le M colonne consecutive rappresentano i vari intervalli temporali, cioè i mesi degli anni che vanno dal 2016 al 2020. Ciascun vettore colonna di questa matrice esprime formalmente un **Graph Signal** $x \in R^N$.

2. Graph Learning

2.1 Analisi Spettrale nel Dominio GFT e Fondamenti Teorici del Filtraggio

Dato un grafo non orientato $G(\mathcal{V}, \mathcal{E})$ con N vertici, la struttura topologica e le relazioni di adiacenza tra i nodi sono codificate all'interno della matrice Laplaciana, definita come:

$$L = D - A \quad (2.1)$$

dove $A \in R^{N \times N}$ rappresenta la matrice di adiacenza (geometrica A_{geo} o ottimizzata A_{ottimale}) e D è la matrice diagonale dei gradi. Essendo L una matrice reale e simmetrica per grafi non orientati, essa ammette una decomposizione spettrale della forma:

$$L = U \Lambda U^T \quad (2.2)$$

In questa formulazione, $\Lambda = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_N)$ presenta gli autovalori sulla diagonale principale. La matrice ortogonale $U = [u_1, u_2, \dots, u_N] \in R^{N \times N}$ estrae la base ortonormale degli autovettori del Laplaciano.

Dato un *Graph Signal* (segnale sul grafo) definito come un vettore colonna $x \in R^N$, la *Graph Fourier Transform* (GFT) mappa l'informazione spaziale dei nodi nel dominio delle frequenze spettrali attraverso l'operatore di proiezione:

$$\hat{x} = U^T x \quad (2.3)$$

Viceversa, l'operazione opposta è effettuata tramite *Inverse Graph Fourier Transform* (IGFT), che esprime il segnale originario come:

$$x = U \hat{x} = \sum_{i=1}^N \hat{x}_i u_i \quad (2.4)$$

Da questa relazione si deduce che gli autovalori piccoli corrispondono a basse frequenze (variazioni lente e regolari tra nodi interconnessi), mentre quelli grandi indicano oscillazioni brusche e localizzate. Un segnale è considerato strettamente *smooth* sulla rete se la sua GFT concentra la maggior parte dell'energia nei coefficienti principali a bassa frequenza.

Una volta imparato un grafo in cui il segnale risulta *smooth* tramite A_{ottimale} , è possibile quindi definire un filtro passa-basso per filtrare le componenti più significative e poi ricostruire il segnale originale con meno componenti, scegliendo sul grafo indotto le componenti spettrali associate agli autovalori più bassi dello spettro.

L'impatto di questa troncatura ideale viene esaminato dinamicamente al variare dello spettro di taglio misurando la distorsione spettrale indotta tramite la metrica del *Mean Squared Error* (MSE) di ricostruzione:

$$\text{MSE} = \frac{1}{N} \|x - x_{\text{rec}}\|_2^2 = \frac{1}{N} \sum_{i=1}^N (x_i - x_{\text{rec},i})^2 \quad (2.5)$$

2.2 Costruzione Matrice di Adiacenza basata su distanza

Per prima cosa si è quindi proceduto alla costruzione delle matrici di adiacenza. La matrice di adiacenza geometrica viene costruita calcolando per ciascuna coppia di nodi distinti ($i \neq j$) la seguente funzione di Kernel Gaussiano:

$$A_{\text{geo}}(i, j) = \exp \left(-\frac{D_{\text{geo}}(i, j)^2}{2\beta^2} \right) \quad (2.6)$$

Dove:

- **Il numeratore $D_{\text{geo}}(i, j)^2$:** Rappresenta il quadrato della distanza euclidea spaziale tra il nodo i e il nodo j , calcolata a partire dalle rispettive coordinate geografiche di latitudine e longitudine. Grazie al segno meno davanti, per nodi infinitamente vicini la distanza tende a zero e il peso dell'arco converge al valore massimo ($e^0 = 1$), mentre al crescere della distanza il peso decade in modo continuo verso lo zero.
- **Il denominatore $2\beta^2$:** Il parametro β^2 serve invece come fattore di normalizzazione, poichè essendo calcolato come la media della distanza tra i vari quartieri, fa capire al Kernel cosa è lontano e cosa vicino; Senza di esso i nodi tenderebbero ad isolarsi.

2.3 Apprendimento del Grafo Ottimo tramite Algoritmo ADMM Scalato

Per prima cosa è necessario definire formalmente il problema di ottimizzazione. L'obiettivo consiste nel determinare la matrice di adiacenza ottimale $A \in R^{N \times N}$ formulando il seguente problema di ottimizzazione convessa vincolata:

$$\begin{aligned} \min_A \quad & \frac{1}{2} \sum_{i,j=1}^N A_{ij} Z_{ij} - \alpha \sum_{i=1}^N \log \left(\sum_{j=1}^N A_{ij} \right) \\ \text{s.t.} \quad & A_{ij} = A_{ji} \quad \forall i, j \\ & A_{ij} \geq 0 \quad \forall i, j \\ & A_{ii} = 0 \quad \forall i \end{aligned} \tag{2.7}$$

Questo è una variante adattata al dataset in esame del framework di Kalofolias. Dove

$$Z_{ij} = \sum_{k=1}^M (X_{ik} - X_{jk})^2$$

è un indice di dissimiglianza tra il comportamento del nodo i e del nodo j . L'obiettivo è di capire quanto sono diversi i comportamenti tra due nodi:

- Se Z_{ij} è vicino a 0, i due nodi sono quasi identici.
- Se Z_{ij} è vicino a 1, i nodi hanno comportamento opposto.

La matrice Z viene poi normalizzata tra 0 e 1 dividendo per il suo valore massimo. La funzione obiettivo da minimizzare è strutturata esclusivamente su due termini:

1. **Il termine di Smoothness** ($\frac{1}{2} \sum A_{ij} Z_{ij}$): Decide i collegamenti in base alla dissimiglianza, se due nodi sono molto diversi e quindi hanno Z_{ij} vicino a 1 l'unico modo per non far crescere esponenzialmente il costo totale è settare A_{ij} a 0, se invece Z_{ij} è piccola l'algoritmo può assegnare un peso ad A_{ij} .
2. **Il termine Logaritmico** ($-\alpha \sum \log(\sum A_{ij})$): Agisce come regolarizzatore spingendo il grado complessivo di ogni singolo nodo verso valori positivi. Questo termine impedisce matematicamente l'isolamento dei nodi, controllando la connettività e la densità complessiva della rete tramite il parametro α .
3. **I vincoli**: Impongono che la matrice finale rispetti le proprietà geometriche fondamentali di un grafo stradale semplice e non orientato: la simmetria dei pesi ($A_{ij} = A_{ji}$), la non-negatività degli archi ($A_{ij} \geq 0$) e il divieto di auto-anelli sulla diagonale principale ($A_{ii} = 0$).

Utilizzando ADMM per risolvere il problema di minimizzazione si introduce una seconda variabile ausiliaria di sdoppiamento $z \in R^{N \times N}$ vincolata dall'uguaglianza rigida $x - z = 0$. Il problema originario viene così riformulato:

$$\begin{aligned}
\min_{x,z} \quad & \frac{1}{2} \sum_{i,j=1}^N x_{ij} Z_{ij} - \alpha \sum_{i=1}^N \log \left(\sum_{j=1}^N z_{ij} \right) \\
\text{s.t.} \quad & x - z = 0 \\
& x_{ij} = x_{ji} \quad \forall i, j \\
& x_{ij} \geq 0 \quad \forall i, j \\
& x_{ii} = 0 \quad \forall i
\end{aligned} \tag{2.8}$$

Si ricava la funzione della Lagrangiana Aumentata scalata che l'algoritmo andrà a minimizzare in modo alternato:

$$L_\rho(x, z, u) = \frac{1}{2} \sum_{i,j=1}^N x_{ij} Z_{ij} - \alpha \sum_{i=1}^N \log \left(\sum_{j=1}^N z_{ij} \right) + \frac{\rho}{2} \|x - z + u\|_2^2 \tag{2.9}$$

dove x e z sono le variabili primarie, u è la variabile duale dei moltiplicatori scalati e ρ è il parametro di penalità quadratica che governa la convergenza.

Si noti un aspetto fondamentale dell'approccio algoritmico implementato: sebbene i vincoli strutturali del grafo siano esplicitati all'interno del problema teorico formalizzato in (2.8), essi non gravano sul carico computazionale del solutore globale sotto forma di barriere o penalità non lineari. Lo schema ADMM consente infatti di farli rispettare per forza e in modo esatto ad ogni ciclo iterativo.

I vincoli originari vengono assorbiti all'interno dei singoli passi operativi applicati direttamente in forma chiusa, tramite:

- **La simmetria spaziale** ($x_{ij} = x_{ji}$): Viene imposta calcolando la semisomma della matrice con la sua trasposta.
- **La non-negatività dei pesi** ($x_{ij} \geq 0$): Viene risolta mediante l'operatore di proiezione sul semispazio positivo, azzerando istantaneamente ogni arco che assume valori negativi tramite il comando `A[A < 0] = 0`.
- **L'assenza di auto-anelli** ($x_{ii} = 0$): Viene garantita resettando a zero la diagonale principale tramite la funzione `np.fill_diagonal(A, 0)`.

Attraverso questa architettura la complessità dell'ottimizzazione viene ridotta.

1. Passo di Minimizzazione rispetto a x (Step X)

Il primo passo consiste nel minimizzare la Lagrangiana rispetto alla variabile primaria x , mantenendo congelate le matrici z e u all'iterazione precedente. Escludendo i termini indipendenti da x , la porzione quadratica da ottimizzare è:

$$\min_x \quad \frac{1}{2} \sum_{i,j=1}^N x_{ij} Z_{ij} + \frac{\rho}{2} \|x - z + u\|_2^2 \quad (2.10)$$

Calcolando il gradiente rispetto a x e uguagliandolo a zero, si ricava in forma chiusa la configurazione ottimale intermedia:

$$\nabla_x L_\rho = \frac{1}{2} Z + \rho(x - z + u) = 0 \implies x = z - u - \frac{Z}{2\rho} \quad (2.11)$$

Vengono poi fatti rispettare i vincoli geometrici come già descritto sopra:

$$x \leftarrow \frac{1}{2} (x + x^T) \quad (2.12)$$

$$x_{ij} \leftarrow \max(0, x_{ij}), \quad x_{ii} \leftarrow 0 \quad (2.13)$$

2. Passo di Minimizzazione rispetto a z (Step Z)

Il secondo passo calcola l'aggiornamento della variabile ausiliaria z risolvendo un problema legato all'operatore di prossimità del logaritmo negativo, partendo dalla matrice di supporto $M = x + u$. L'ottimizzazione viene eseguita riga per riga per ciascun nodo i :

$$\min_{z_{i,:}} \quad -\alpha \log \left(\sum_{j=1}^N z_{ij} \right) + \frac{\rho}{2} \sum_{j=1}^N (M_{ij} - z_{ij})^2 \quad (2.14)$$

Per risolvere analiticamente questo problema ed evitare un'ottimizzazione elemento per elemento, si introduce un cambio di variabile basato sulle proprietà geometriche della norma quadratica. Si definisce il grado complessivo ottimale del nodo i come $d_i = \sum_{j=1}^N z_{ij}$ e la somma della riga corrispondente nella matrice di supporto come $s_i = \sum_{j=1}^N M_{ij}$.

Per minimizzare il termine di distanza quadratica preservando la struttura della riga, la soluzione ottimale impone che il vettore $z_{i,:}$ sia una riscalatura proporzionale del vettore di partenza $M_{i,:}$, ovvero:

$$z_{ij} = M_{ij} \cdot \frac{d_i}{s_i} \quad (2.15)$$

Sostituendo la relazione (2.15) all'interno della (2.14), il problema originario a N variabili si riduce a un problema di ottimizzazione monodimensionale nella sola variabile scalare d_i :

$$\min_{d_i} \phi(d_i) = -\alpha \log(d_i) + \frac{\rho}{2}(d_i - s_i)^2 \quad (2.16)$$

Per calcolare il punto di minimo, si impone la condizione di ottimalità del primo ordine uguagliando a zero la derivata prima della funzione di costo rispetto a d_i :

$$\frac{d\phi}{d(d_i)} = -\frac{\alpha}{d_i} + \rho(d_i - s_i) = 0 \quad (2.17)$$

Moltiplicando l'intera espressione per d_i al fine di eliminare l'incognita al denominatore, si ottiene la seguente equazione di secondo grado:

$$\rho d_i^2 - \rho s_i d_i - \alpha = 0 \quad (2.18)$$

Dividendo per il parametro di penalizzazione ρ , l'equazione assume la forma canonica:

$$d_i^2 - s_i d_i - \frac{\alpha}{\rho} = 0 \quad (2.19)$$

Applicando la formula risolutiva delle equazioni di secondo grado, si determinano le due radici:

$$d_i = \frac{s_i \pm \sqrt{s_i^2 + \frac{4\alpha}{\rho}}}{2} \quad (2.20)$$

Poiché il grado del nodo deve essere strettamente positivo affinché l'argomento del logaritmo sia ben definito ($d_i > 0$), la radice negativa viene scartata. Sostituendo nuovamente $s_i = \sum_{j=1}^N M_{ij}$, si determina analiticamente il valore ottimale della somma dei pesi di riga:

$$\text{grado_ottimo}_i = \frac{1}{2} \left(\sum_{j=1}^N M_{ij} + \sqrt{\left(\sum_{j=1}^N M_{ij} \right)^2 + \frac{4\alpha}{\rho}} \right) \quad (2.21)$$

Ottenuto il vincolo di grado ottimale, l'algoritmo provvede alla ridistribuzione proporzionale dei pesi lungo la riga i per preservare l'informazione strutturale ereditata da M :

$$z_{ij} = \begin{cases} M_{ij} \cdot \left(\frac{\text{grado_ottimo}_i}{\sum_{j=1}^N M_{ij}} \right) & \text{se } \sum_{j=1}^N M_{ij} > 0 \\ \frac{\text{grado_ottimo}_i}{N} & \text{se } \sum_{j=1}^N M_{ij} = 0 \end{cases} \quad (2.22)$$

Nel caso limite in cui la somma degli elementi di supporto sia nulla o negativa, l'assenza di informazione a priori sulla connettività del nodo impone una ripartizione uniforme del grado ottimale su tutti gli N archi della riga. A conclusione dello step, la struttura geometrica globale viene simmetrizzata e la diagonale azzerata ponendo $z \leftarrow 0.5 \cdot (z + z^T)$ e $z_{ii} \leftarrow 0$.

3. Aggiornamento della Variabile Duale (Step U)

La variabile duale scalata u viene aggiornata integrando il residuo primario registrato al termine del ciclo corrente, ovvero lo scostamento istantaneo tra le due variabili primarie:

$$u \leftarrow u + x - z \quad (2.23)$$

Criterio di Arresto e Convergenza

Il processo iterativo viene interrotto prima del limite prefissato se la variazione relativa della matrice del grafo x tra due iterazioni consecutive scende sotto la tolleranza impostata, misurata tramite il rapporto normalizzato delle norme di Frobenius:

$$\text{residuo} = \frac{\|x - x_{\text{old}}\|_F}{\|x_{\text{old}}\|_F} < \text{tol} \quad (2.24)$$

Al raggiungimento della convergenza, l'algoritmo restituisce la matrice x ottimizzata.

3. Risultati e test

Dopo aver estratto le matrici di adiacenza ottimali e aver calcolato la scomposizione in autovalori e autovettori, è stata ricavata la base U della GFT (Graph Fourier Transform). Si è proceduto, quindi, al test di ricostruzione del segnale considerando esclusivamente una porzione ridotta delle componenti spettrali dei due grafi.

Il confronto è stato effettuato sul segnale del mese di marzo 2023 (corrispondente all'ultima colonna del dataset), paragonando l'andamento reale degli incidenti con quello ricostruito tramite il grafo appreso e il grafo basato sulla distanza fisica. I test sono stati condotti al variare delle componenti spettrali utilizzate, impostando tre differenti valori di K ($K = 10, 50, 100$):

Come si evince dalla Figura 3.1, in cui il profilo nero rappresenta l'andamento reale degli incidenti, la linea blu tratteggiata indica la ricostruzione geometrica e la linea rossa rappresenta la ricostruzione ottimale, il grafo associato alla matrice A_{ottimale} mostra prestazioni nettamente superiori. Già con sole $K = 10$ componenti spettrali, il modello appreso riesce a intercettare alcuni picchi locali che il grafo basato sulla sola distanza fisica smussa completamente.

La differenza cruciale emerge tuttavia aumentando il numero di componenti spettrali: con $K = 50$ e $K = 100$, il segnale viene ricostruito in modo estremamente fedele dal grafo ottimizzato (con un MSE che crolla drasticamente), laddove il grafo geometrico non riesce a seguire le variazioni repentine e le alte frequenze spaziali presenti all'interno del dataset.

Anche l'analisi dell'andamento dell'MSE, effettuata con $5 < k < 145$ tramite salti di 5, al variare del numero di componenti K , mostrata in Figura 3.2, conferma quantitativamente la validità della ricostruzione ottimale. L'errore del grafo appreso decresce in maniera molto rapida, tendendo ad appiattirsi già intorno alle 80 componenti spettrali utilizzate. Al contrario, l'errore associato al grafo basato sulla distanza geometrica mostra una discesa decisamente più lenta e lineare, mantenendo valori di MSE nettamente superiori a parità di spettro troncato.




Figura 3.1: Confronto spettrale della ricostruzione del segnale degli incidenti stradali per $K = 10$, $K = 50$ e $K = 100$ autovettori. Vengono messi a confronto il segnale reale (nero), la ricostruzione tramite grafo geometrico (blu) e la ricostruzione tramite grafo appreso via ADMM (rosso).




Figura 3.2: Andamento dell'errore quadratico medio (MSE) di ricostruzione al variare del numero di componenti spettrali K per il grafo geometrico (blu) e per il grafo appreso (rosso).

Ciò dimostra empiricamente che l'algoritmo di Graph Learning, imponendo il vincolo di *smoothness* sul segnale storico, è stato in grado di catturare efficacemente la reale topologia sottostante del fenomeno. Concentrando la maggior parte dell'energia e dell'informazione del segnale sulle basse frequenze dello spettro delle frequenze del grafo, il modello ottimizzato consente una rappresentazione estremamente parsimoniosa ed efficace, proprietà che invece non emerge dalla semplice vicinanza fisica dei nodi.

Per validare matematicamente le proprietà di filtraggio della struttura ottimizzata, è stato condotto un esperimento duale rispetto ai precedenti, volto a testare la selettività spettrale della base U_{learned} . È stato generato un segnale artificiale ad altissima frequenza spaziale, isolando l'ultimo autovettore del Laplaciano ottimizzato, il quale rappresenta per definizione il segnale a minima regolarità (*non-smooth*) per tale topologia.




Figura 3.3: Errore di ricostruzione (MSE) al variare del troncamento spettrale K per un segnale sintetico ad alta frequenza spaziale.

I risultati illustrati in Figura 3.3 offrono una controprova fondamentale. L'errore di ricostruzione del grafo appreso (linea rossa) rimane costante e massimo per l'intero intervallo di K analizzato. Questo comportamento, apparentemente dicotomico rispetto ai test sui dati reali, dimostra l'estrema selettività energetica del modello: l'algoritmo ADMM ha confinato l'intero spettro del segnale di interesse nelle armoniche inferiori.

Di contro, la parziale discesa dell'errore per il grafo geometrico (linea blu) evidenzia come quest'ultimo non possieda una chiara separazione spettrale per il fenomeno in esame, disperdendo l'energia del segnale in modo inefficiente lungo diverse componenti dello spettro.

L'efficacia del framework di Graph Learning proposto viene anche validata attraverso la ricostruzione del segnale reale relativo al numero di incidenti stradali registrati nel mese di Marzo 2023 nella rete urbana. I nodi del grafo rappresentano le celle territoriali dei vari quartieri, mentre l'intensità del colore codifica la densità degli eventi registrati o stimati, evidenziando picchi localizzati ad alta criticità (corrispondenti alle tonalità più scure).




Figura 3.4: **Confronto spaziale delle metodologie di ricostruzione del segnale.** (1) Mappa originale dei sinistri registrati a Los Angeles (Marzo 2023). (2) Ricostruzione basata su un grafo puramente geometrico ($K = 50$). (3) Ricostruzione ottimale tramite il grafo appreso con l'algoritmo ADMM ($K = 50$)

L'analisi visiva conferma che l'algoritmo ADMM basato sull'ottimizzazione del termine di *smoothness* e sulla regolarizzazione logaritmica è in grado di estrarre dal segnale originale le reali correlazioni nascoste del tessuto urbano, superando le limitazioni dei modelli geometrici standard e offrendo uno strumento predittivo ad alta risoluzione per il monitoraggio della sicurezza stradale.

4. Conclusioni

In questo progetto abbiamo sviluppato e testato un algoritmo di *Graph Learning* basato su ADMM per ricostruire il segnale degli incidenti stradali nei quartieri di Los Angeles.

I risultati parlano chiaro: mentre un approccio geometrico standard (basato solo sulla vicinanza fisica) fallisce perché "appiattisce" troppo i dati (*over-smoothing*), il grafo ottimizzato appreso dai dati reali si è dimostrato superiore. L'algoritmo è riuscito, infatti, a connettere i quartieri in base al loro effettivo comportamento storico, ricostruendo con grande precisione i picchi e le zone a più alto rischio di incidentalità.

Dal punto di vista pratico, l'uso dell'ADMM è stato la chiave di volta: traducendo i vincoli matematici (simmetria, non-negatività e diagonale nulla) in semplici operazioni matriciali, permettendo di mantenere il codice semplice e rapido nell'esecuzione.

In conclusione, il modello si è rivelato uno strumento solido ed efficiente.